Implementación de una Red Neuronal Informada por la Física (PINN) para la obtención de perfiles de densidad y temperatura para un plasma que presenta un transporte clásico.

Aaron Sanabria Martínez - estudiante* and Ricardo Solano Piedra- supervisor**
Escuela de Física, Universidad de Costa Rica
(Dated: 23 de marzo de 2026)

1. Introducción

El *deep learning* DL se ha integrada a la física por su capacidad de representar funciones complejas y aprender estructuras de relaciones matemáticas [1]. Dentro de estas, las redes neuronales NNs destacan por su capacidad para aproximar funciones postulándolas como una opción para la resolución de sistemas diferenciales [2]. Las redes neuronales informadas por la física PINNs permiten tratar sistemas complejos de ecuaciones diferenciales usando restricciones físicas para obtener soluciones. Herramientas como la auto-diferenciación permiten introducir las ecuaciones diferenciales EDs y sus condiciones de frontera como funciones de penalización que restringen el espacio de soluciones y explotan la capacidad de aproximación de las redes neuronales NNs [3, 4].

Hay un campo en la física que presenta no linealidad y acoplamiento en las ecuaciones que lo rigen. La dinámica de los plasmas está influenciado por interacciones electromagnéticas [5]. Estos sistemas son complejos debido a su comportamiento colectivo y una dinámica con múltiples regímenes de colisión que llevan al transporte de partículas [6]. La descripción de fluidos del plasma da un sistema cerrado de ecuaciones diferenciales parciales PDEs que puede ser modelado con teoría de transporte clásico [7]. Pese a que estos sistemas pueden ser reducidos a uno de ecuaciones diferenciales ordinarias ODEs con modelos 1D, siguen siendo complejos de tratar[8, 9].

Los coeficientes y los términos fuentes en los sistemas de EDs que aparecen en los modelos de transporte colisional no son constantes, además son no lineales por lo que el uso de PINNs es una buen método por su capacidad de integrar y representar la no linealidad [10]. Por ejemplo, se han implementado PINNs para la resolución de ecuaciones unidimensionales del transporte de plasma a bajas temperaturas[10, 11]. Esquemas de PINNs aplicados en el transporte en Tokamaks han sido comparados con métodos tradicionales de diferencias finitas en la resolución de PDEs con beneficios como reducción en el tiempo de convergencia [12]. En el transporte turbulento para encontrar campos consistentes con las ecuaciones del fluido doble de Braginskii [13]. La determinación de los perfiles electrónicos de densidad y temperatura en plasma magnetizado usando modelos 1D bajo modelos de transporte clásico se plantea resolver en este trabajo.

2. Marco Teórico

2.1. Redes Neuronales Informadas por la física: fundamentos

Las **neuronas** artificiales son funciones matemáticas y son la estructura básica de las redes neuronales NNs. Las neuronas se conectan entre sí usando **capas** que toman de argumentos vectores de salidas de capas previas. Los perceptrones multicapa MLP son una NN completamente conectada donde la información fluye únicamente de la **capa de entrada** a la **capa de salida**, sin ciclos ni retroalimentación, i.e., $\mathcal{F} : X \to Y$ con $\mathcal{F} = f^{(L)} \circ f^{(L-1)} \circ \cdots \circ f^{(1)}$ con X es el espacio de entradas y Y el espacio de salidas. Cada **capa** aplica una transformación afín seguida de una **activación** no lineal por la función $\sigma(\cdot)$ que debe ser diferenciable.

$$f^{(k)}(\boldsymbol{x}_{k-1}) = \sigma(\boldsymbol{W}^{(k)}\boldsymbol{x}_{k-1} + \boldsymbol{b}^{(k)})$$

*Electronic address: aaron.sanabria@ucr.ac.cr
**Electronic address: risolano@itcr.ac.cr

donde $\boldsymbol{W}^{(k)}$ una matriz de pesos y $\boldsymbol{b}^{(k)}$ el **sesgo**, son parámetros de la NN que se ajustan durante el entrenamiento. Una función general continua puede ser aproximada con precisión arbitraria usando MLPs [14, 15].

En la figura 1 se muestra el esquema general de lo que es un MLP.

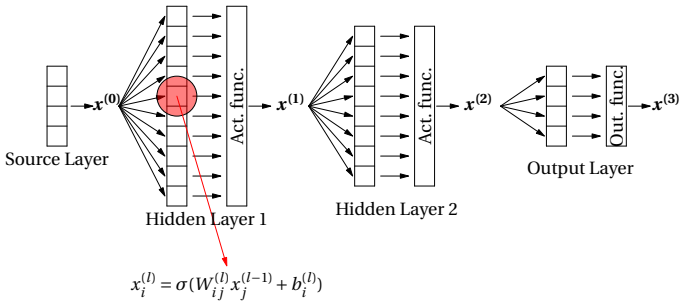

Figura 1: MLP con dos capas ocultas. Adaptado de [16] bajo licencia CC BY-NC-SA 4.0.

Las entradas, salidas y transformaciones en las NNs se guardan en tensores que almacenan los parámetros e híper-parámetros de la MLP, así como el grafo de computo de las operaciones sobre ellos y sus derivadas locales. Esto da paso al concepto de **autodiferenciación** AD.

AD es un método de diferenciación que parte del principio de que toda operación computacional puede ser descompuesta en operaciones elementales con derivadas conocidas. Aplicando la regla de la cadena al grafo de cómputo, se obtiene la derivada en dos maneras, **diferenciación hacia adelante** donde se parte de las entradas y propaga las derivadas hacia las salidas y **diferenciación hacia atrás** que parte de las salidas y propaga las derivadas hacia todos los parámetros del modelo [4]. La función de activación debe ser diferenciable en los puntos donde se aplica AD para evitar problemas con las derivadas.

2.1.1. Funciones de pérdida y PINNs

Las **funciones de pérdida** $\mathcal{L}(\{x_i\}, \theta)$ cuantifican cuánto se apegan los modelos a las restricciones que se le imponen en determinados puntos $\{x_i\} \in X$ conocidos como **puntos de colocación**. Durante el entrenamiento se minimiza $\mathcal{L}(\boldsymbol{\theta})$ al variar los parámetros internos del modelo $\boldsymbol{\theta} := \{\boldsymbol{W}^{(k)}, \boldsymbol{b}^{(k)}\}$. Las funciones $\mathcal{L}(\boldsymbol{\theta})$ pueden contener multiples términos correspondientes a diferentes condiciones sobre el modelo, si se imponen sobre las ecuaciones diferenciales EDs que rigen un sistema físico y sus condiciones de frontera, surge el concepto de **red neuronal informada por la física** PINN [3].

Las NNs requieren tanto de los parámetros $\boldsymbol{\theta}$ como de los híper-parámetros de la red $\boldsymbol{\Theta}$ que contienen el número de capas $L+1$, el ancho de la red, la función de activación que se usa σ, etc. Una arquitectura de NN robusta requiere de una fase de entrenamiento donde se optimizan los valores de $\boldsymbol{\theta}$ dado un conjunto de $\boldsymbol{\Theta}$ fijos[16].

2.1.2. Optimizadores

Los algoritmos de optimización modernos parten del algoritmo de **descenso por gradiente** GD, donde se usa la dirección opuesta al gradiente de $\mathcal{L}(\boldsymbol{\theta})$ y un híper-parámetro llamado **tasa de aprendizaje** η que es el tamaño del paso usado, para actualizar de forma iterativa los parámetros de la red tal que $\boldsymbol{\theta} \to \boldsymbol{\theta} - \eta \nabla_\theta \mathcal{L}$. El método es en general lento, pero es la base de algoritmos más eficientes.

Los algoritmos basados en GD pueden desvanecerse o explotar. Esto se previene controlando la varianza de las señales que se pasan a la NN al **inicializar** los parámetros con valores aleatorios de una distribución uniforme o normal. El inicializador **Xavier** trata las derivadas de la función de perdida como variables aleatorias [17].

El estimador adaptativo de momentos **Adam** está basado en gradientes estocásticos de primer orden donde las η son adaptativas. Se introducen momentos que guardan el historial del gradiente $\nabla_{\boldsymbol{\theta}} \mathcal{L}$. Los momentos son las medias móviles exponenciales del gradiente, el primer momento y del cuadrado del gradiente, el segundo momento. El método es robusto para tratar problemas dispersos y con ruido [18].

El algoritmo de memoria limitada Broyden-Fletcher-Goldfarb-Shanno **L-BFGS** es un método de memoria cuasi-newtoniano de segundo orden que estima la matriz hessiana de $\mathcal{L}(\boldsymbol{\theta})$ respecto a los parámetros sin calcular todos los elementos de la matriz, cerca de un mínimo la convergencia es más rápida que en métodos de primer orden. El costo computacional escala con el número de gradientes almacenados y no con el número de parámetros.

2.2. Plasmas magnetizados y teoría clásica de transporte perpendicular

Un **plasma** es un gas ionizado que presenta comportamiento colectivo y cuasi-neutralidad. La dinámica del plasma está gobernada por interacciones electromagnéticas de largo alcance tanto por campos que se generan a nivel interno como por campos exteriores. La teoría de transporte colisional estudia el transporte de partículas, momento y energía en un régimen dominado por colisiones elásticas e inelásticas entre las especies del plasma

que determinan el transporte y los procesos atómicos. Cuando partículas, momento y energía se transportan en dirección perpendicular a un campo magnético establecido en el plasma se alude al concepto de **transporte perpendicular**. La teoría de transporte clásico estudia la contribución de las colisiones al transporte perpendicular en un plasma magnetizado [5].

2.2.1. Ecuación Cinética de Boltzmann

Una descripción estadística asume que hay suficientes partículas en el sistema para tener una descripción macroscópica con temperatura y densidad bien definidas. Se trabaja en un espacio de fase 6-dimensional $(\boldsymbol{x}, \boldsymbol{v})$. Primero se introduce el operador d/dt como

$$\frac{d}{dt} \equiv \partial_t + \mathbf{v} \cdot \nabla + \frac{Z_\alpha e}{m_\alpha}(\mathbf{E} + \mathbf{v} \times \mathbf{B}) \cdot \nabla_{\mathbf{v}}$$

este operador toma en cuenta la evolución temporal local, la advección espacial y la interacción electromagnética con campos externos. Las especies en un plasma pueden ser especificadas por una función de distribución $f_\alpha(\boldsymbol{x}, \boldsymbol{v}, t)$ mediante la siguiente ecuación:

$$\left[\frac{d}{dt} - C_{\alpha,\beta}\right] f_\alpha = 0 \tag{1}$$

en este caso $C_{\alpha,\beta}$ es un operador de colisiones binarias entre especies α y β que describe colisiones que se dan en el medio.

Al integrar la ecuación (1) respecto al espacio de velocidades con pesos g_k correctos se puede obtener la descripción de fluidos en el plasma al tomar los momentos $k = 0$ y $k = 2$. La ecuación (2) describe el flujo de partículas de plasma a partir de g_0

$$\partial_t n_\alpha + \nabla \cdot \mathbf{\Gamma}_\alpha = S_\alpha \tag{2}$$

con n_α y $\boldsymbol{u}_\alpha$ la densidad y velocidad promedio del plasma respectivamente, $\mathbf{\Gamma}_\alpha = n_\alpha \boldsymbol{u}_\alpha$ el flujo de partículas y S_α un término de fuentes y sumideros. Por otro lado, la ecuación (3), que describe el flujo de energía en el plasma, se obtiene a partir de g_2

$$\partial_t W_\alpha + \nabla \cdot \boldsymbol{Q}_\alpha = P_\alpha \tag{3}$$

con W_α la densidad de energía del sistema, $\boldsymbol{Q}_\alpha$ el flujo de energía y P_α términos de potencia y disipación de energía [5, 7].

2.2.2. Colisiones y procesos atómicos en el plasma

Las colisiones en el plasma producen procesos atómicos como la ionización, radiación, recombinación y colisiones de Coulomb. Esto se traduce en términos de fuente y sumideros como en las ecuaciones (2) y (3). Cada proceso puede modelarse como [6]

$$\begin{aligned} S_{\text{proceso}} &= n_\alpha n_\beta \langle \sigma v \rangle_{\text{proceso}} \\ P_{\text{proceso}} &= E_{\text{proceso}} n_\alpha n_\beta \langle \sigma v \rangle_{\text{proceso}} \end{aligned}$$

donde σ es la sección efectiva de la colisión. Los términos de fuente y sumidero de partículas así como la energía dependen de $\langle \sigma v \rangle$ la tasa a la cual ocurren las colisiones que dan lugar al proceso atómico.

2.2.3. Procesos de calentamiento en el Plasma

En los procesos de calentamiento se debe considerar el esfuerzo viscoso en el plasma $\mathbf{\Pi}_\alpha$ y la presión mecánica p_α. El flujo de calor $\boldsymbol{Q}_\alpha$ puede dividirse en diferentes contribuciones tal que

$$\mathbf{Q}_\alpha = \mathbf{q}_\alpha + \frac{3}{2} T_\alpha \mathbf{\Gamma}_\alpha + p_\alpha \mathbf{u}_\alpha + \mathbf{\Pi}_\alpha \cdot \mathbf{u}_\alpha + \frac{1}{2} m_\alpha u_\alpha^2 \mathbf{\Gamma}_\alpha \tag{4}$$

Las diferentes contribuciones de flujos corresponden en orden a: calentamiento conductivo, convectivo, la entalpía o trabajo que hace la presión mecánica sobre el plasma, el transporte viscoso de energía y la convección de energía cinética [5]. Bajo ciertos supuestos es posible despreciar algunas de estas contribuciones.

2.2.4. Parámetros característicos del plasma

El radio de Debye $\lambda_D = \sqrt{\epsilon_0 T / n_e e^2}$ es una distancia en la que el potencial de Coulomb se ve apantallado por comportamiento colectivo de las partículas. Con λ_D y el parámetro de impacto mínimo $b_{\min}$ se define la cantidad $\Lambda \equiv \lambda_D / b_{\min} = 4\pi\epsilon^{3/2} e^{-3} T_e^{3/2} n_e^{-1/2}$ [5, 6]. Suele aparecer como $\ln \Lambda$ bajo el nombre de logaritmo de Coulomb. Se define el tiempo de relajación $\tau_{\alpha,\beta}$ que es el periodo típico entre colisiones electrónicas

$$\tau_{e,i}^{-1} = \left(\frac{e^2}{4\pi\epsilon_0}\right)^2 \frac{8\sqrt{2\pi m_e n_e}}{3 m_i} \frac{\ln \Lambda}{T_e^{3/2}}$$

En el plasma se da difusión de partículas y energía. Para un plasma cilíndrico con $\boldsymbol{B}$ uniforme y presión constante, los flujos tienen la forma [5]

$$\mathbf{\Gamma}_e \approx -D_\perp(n_e, T_e) \partial_r n_e \quad \text{con} \quad D_\perp = \frac{T_e}{m_e \omega_e^2 \tau_{ei}} \tag{5}$$

$$\boldsymbol{q}_e \approx -\chi_\perp(n_e, T_e) \partial_r T_e \quad \text{con} \quad \chi_\perp = 4{,}66 \frac{n_e T_e}{m_e \omega_e^2 \tau_{ei}} \tag{6}$$

con ω_e es la frecuencia ciclotrónica del electrón.

3. Planteamiento del Problema

Las PINNs se han implementado en el estudio de transporte [12, 13], pero no se ha reportado su uso para el caso del transporte perpendicular para una geometría cilíndrica en la solución de las ecuaciones de fluido de Braginskii como un problema de ODEs con coeficientes dependientes de los perfiles. Las PINNs integran la no linealidad y la física al problema directamente en las funciones de pérdida usando AD sin uso de grillas. En este contexto se plantea si es posible obtener una solución usando únicamente estas restricciones y si los perfiles obtenidos constituyen una primera aproximación a los perfiles electrónicos n y T en el dispositivo RTP.

4. Objetivo General

Implementar una Red Neuronal Informada por la Física (PINN) para la determinación de los perfiles radiales de densidad electrónica y temperatura electrónica en un plasma magnetizado cilíndrico que exhibe transporte clásico perpendicular al campo magnético.

Objetivos específicos

1. Formular las ecuaciones que relacionan la densidad electrónica y temperatura electrónica a partir de la teoría de transporte clásico perpendicular al campo magnético para la base del diseño de la PINN.
2. Diseñar la arquitectura de la PINN de acuerdo al modelo teórico mediante la definición de las capas, las funciones de activación y los híper-parámetros esenciales de la red.
3. Validar los resultados de la PINN con una comparación de los perfiles obtenidos experimentales del dispositivo RTP para evaluar el grado de fidelidad y precisión del modelo computacional implementado.

5. Metodología

Para la derivación teórica de las ecuaciones que determinan los perfiles de densidad n y temperatura T electrónicos, se parte de las ecuaciones (2), (3) y de los siguientes supuestos:

- Cuasi-neutralidad: $n_i \approx n_e$.
- Plasma débilmente ionizado: $n_e \ll n_0$.
- Plasma frío: $T_i \ll T_e$.
- Caso estacionario con difusión ambipolar $\boldsymbol{\Gamma}_i \approx \boldsymbol{\Gamma}_e$.
- Geometría cilíndrica del plasma con transporte en la dirección radial: $T_e = T_e(r)$, $n_e = n_e(r)$.
- La temperatura y densidad son continuas y diferenciables a lo largo del plasma.
- Campo magnético $\boldsymbol{B}$ uniforme en la dirección $\hat{z}$ y campo eléctrico externo $\boldsymbol{E} = \boldsymbol{0}$.
- La densidad de neutros es aproximadamente uniforme en el espacio $n_0 \approx$ constant.
- La deposición de potencia en el plasma sigue un perfil gaussiano $P(r) = P_{\text{ext}}\mathcal{N}(r;\mu,\sigma)/N$ normalizado por N .
- El flujo de energía está dominado por convección y conducción: $\boldsymbol{Q} \approx \boldsymbol{q} + \frac{3}{2}T\boldsymbol{\Gamma}$

A partir de ahora se omitirá la etiqueta α que caracteriza la especie. Se llegará a un sistema de ODEs donde los perfiles serán normalizados respecto a $n_{\max}$ y $T_{\max}$ asumiendo que los perfiles alcanzan su máximo en el centro del plasma. El sistema resultante es de la forma

$$\begin{cases} F(r, \partial_r\hat{n}, \partial_r\hat{T}, \partial_r^2\hat{n}, \partial_r^2\hat{T}, \boldsymbol{\Psi}) = 0, \quad r \in [0, R] \\ G(r, \partial_r\hat{n}, \partial_r\hat{T}, \partial_r^2\hat{n}, \partial_r^2\hat{T}, \boldsymbol{\Psi}) = 0, \\ \hat{n}(0) - 1 = 0, \quad \partial_r\hat{n}\big|_{r=0} = 0, \\ \hat{T}(0) - 1 = 0, \quad \partial_r\hat{T}\big|_{r=0} = 0, \\ \partial_r\hat{n}\big|_{r=R} + \hat{n}(R)/\lambda_n = 0 \\ \partial_r\hat{T}\big|_{r=R} + \hat{T}(R)/\lambda_T = 0 \end{cases} \tag{7}$$

donde λ_n y λ_T son las escalas características de decaimiento en $r = R$ y con $\boldsymbol{\Psi} = \{R, B, n_0, P_{\text{ext}}, \lambda_n, \lambda_T, \mu, \sigma\}$ el conjunto de parámetros libres del sistema. R, el radio del plasma cilíndrico. Las condiciones en $r = 0$ corresponden a la simetría axial del sistema. El orden dos es de esperar por las ecuaciones (5)

5.1. Implementación de la PINN

Se construirá una MLP inicializada con Xavier activada por una función tanh. Consistirá de una capa de entrada r, múltiples capas ocultas L y una capa de salida con dos neuronas $[\hat{n}(r;\boldsymbol{\theta}), \hat{T}(r;\boldsymbol{\theta})]$ en Python usando PyTorch [20] para construir la PINN. Se entrenará con GPUs del clúster de la Universidad de Costa Rica. Las funciones de pérdida serán puramente físicas de la forma [3]:

$$\mathcal{L}(r;\boldsymbol{\theta}) = \omega_{\mathcal{N}}\mathcal{L}_{\mathcal{N}}(r;\boldsymbol{\theta}) + \omega_{bc}\mathcal{L}_{bc}(r;\boldsymbol{\theta})$$

con

$$\begin{aligned} \mathcal{L}_{\mathcal{N}}(r;\boldsymbol{\theta}) &= \frac{1}{N_{\mathcal{N}}}\sum_{I=1}^{N_{\mathcal{N}}} ||\mathcal{N}(r, \partial_r\hat{n}, \partial_r\hat{T}, \partial_r^2\hat{n}, \partial_r^2\hat{T}, \boldsymbol{\Psi})||_2^2 \\ \mathcal{L}_{bc}(r;\boldsymbol{\theta}) &= \frac{1}{N_{bc}}\sum_{i=1}^{N_{bc}} ||f_{bc}(r_0)||_2^2 \end{aligned}$$

aquí N_i y ω_i son los puntos de colocación y pesos para las funciones de pérdida respectivamente que determinarán experimentalmente junto con L para mejorar la convergencia . $\mathcal{L}_{\mathcal{N}}$ corresponde a la contribución de la restricción impuesta por las ODEs $\mathcal{N} = (F, G)$ y sus condiciones de frontera $\mathcal{L}_{bc}$ por $f_{bc}(r_0) = 0$ evaluadas en los extremos $r_0 = 0$ y $r_0 = R$.

Para optimizar la PINN se usará el esquema de dos optimizadores. Una primera optimización con Adam seguida de un refinamiento usando L-BFGS.

Dentro de (7) aparecen términos de disipación de energía y partículas relacionadas con las tasas $\langle \sigma v \rangle$, estas dependen de la temperatura y se determinan numéricamente de la base de datos ADAS con la librería *Cherab v1.5* [21] para un gas de Hidrógeno usado en los disparos elegidos del tokamak RTP.

5.2. Obtención de datos para comparar perfiles

A partir de $n(r)$ y $T(r)$ de la PINN se compararán con perfiles medidos para el dispositivo RTP en los disparos #96040237, #97052261 y #97053056. Se promediarán temporalmente para obtener perfiles estacionario. Los datos serán obtenidos de la base de datos IMDB [22] usando MDSPlus [23].

6. Cronograma

Tabla I: Cronograma de trabajo para el projecto de investigación.

Semana	**Actividad**
09 - 27 de Marzo	Revisión bibliográfica / Escritura de Anteproyecto / Derivación de las ecuaciones del modelo
06 - 10 de Abril	Entrenamiento en la implementación de PINNs
13 de Abril - 01 de Mayo	Redacción del Avance / construir la arquitectura de la PINN
04 - 15 de Mayo	Redacción del Avance / Probar y Ajustar la PINN/
15 - 22 de Mayo	Terminar Avance / obtener y definir los perfiles a usar de la base de datos/ Trabajar en la PINN
22 de Mayo - 12 de Junio	Comparar resultados de la PINN con perfiles de la base de datos.
15 - 03 de Junio	Redacción del Informe Final / Análisis de resultados
06 - 10 de Julio	Trabajar en la presentación y póster/ Correcciones en el informe final

7. Uso de inteligencia artificial

Se usó la LLM Claude para búsqueda bibliográfica, revisión ortográfica y estructural del texto. Se usará para *debugging* de código.

Referencias

[1] G. Carleo, I. Cirac, K. Cranmer, L. Daudet, M. Schuld, N. Tishby, L. Vogt-Maranto, and L. Zdeborová, Rev. Mod. Phys. **91**, 045002 (2019).

[2] I. Lagaris, A. Likas, and D. Fotiadis, IEEE Transactions on Neural Networks **9**, 987 (1998).

[3] M. Raissi, P. Perdikaris, and G. E. Karniadakis, Journal of Computational Physics **378**, 686 (2019).

[4] A. G. Baydin, B. A. Pearlmutter, A. A. Radul, and J. M. Siskind, Journal of Machine Learning Research **18**, 1 (2018).

[5] D. J. S. Per Helander, *Collisional Transport in Magnetized plasmas*, Cambridge Monographs on Plasma Physics (Cambridge University Press, 2005).

[6] G. R.J. and R. P.H., *Introduction to Plasma Physics*, Introduction to Plasma Physics (Taylor & Francis, 1995).

[7] F. J.P., *Ideal MHD* (CUP, 2014).

[8] C. Lechte, J. Stöber, and U. Stroth, Physics of Plasmas **9**, 2839 (2002), https://pubs.aip.org/aip/pop/article-pdf/9/6/2839/19097666/2839_1_online.pdf .

[9] L. L. Alves, A. Bogaerts, V. Guerra, and M. M. Turner, Plasma Sources Science and Technology **27**, 023002 (2018).

[10] L. Zhong, B. Wu, and Y. Wang, Physics of Fluids **34** (2022), 10.1063/5.0106506.

[11] J. Trieschmann, L. Vialetto, and T. Gergs, "Machine learning for advancing low-temperature plasma modeling and simulation," (2023), arXiv:2307.00131 [physics.plasm-ph] .

[12] J. Seo, I. Kim, and H. Nam, Nuclear Engineering and Technology **56**, 5396 (2024).

[13] A. Mathews, M. Francisquez, J. W. Hughes, D. R. Hatch, B. Zhu, and B. N. Rogers, Phys. Rev. E **104**, 025205 (2021).

[14] G. Cybenko, Mathematics of Control, Signals and Systems **2**, 303 (1989).

[15] K. Hornik, M. Stinchcombe, and H. White, Neural Networks **2**, 359 (1989).

[16] D. Ray, O. Pinti, and A. A. Oberai, "Deep learning and computational physics (lecture notes)," (2023), arXiv:2301.00942 [cs.LG] .

[17] X. Glorot and Y. Bengio, in *Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics*, Proceedings of Machine Learning Research, Vol. 9, edited by Y. W. Teh and M. Titterington (PMLR, Chia Laguna Resort, Sardinia, Italy, 2010) pp. 249–256.

[18] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," (2017), arXiv:1412.6980 [cs.LG] .

[19] S. Cuomo, V. S. Di Cola, F. Giampaolo, G. Rozza, M. Raissi, and F. Piccialli, Journal of Scientific Computing **92**, 88 (2022).

[20] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, A. Desmaison, A. Kopf, E. Yang, Z. DeVito, M. Raison, A. Tejani, S. Chilamkurthy, B. Steiner, L. Fang, J. Bai, and S. Chintala, in *Advances in Neural Information Pro-*

cessing Systems 32 (Curran Associates, Inc., 2019) pp. 8024–8035.

[21] C. Giroud, A. Meakins, M. Carr, A. Baciero, and C. Bertrand, "Cherab Spectroscopy Modelling Framework," (2018).

[22] C. M. Roach, M. Walters, R. V. Budny, F. Imbeaux, T. W. Fredian, M. Greenwald, J. A. Stillerman, D. A. Alexander, J. Carlsson, J. B. O. Caughman, *et al.*, Nuclear Fusion **48**, 125001 (2008).

[23] J. A. Stillerman, T. W. Fredian, K. A. Klare, and G. Manduchi, Review of Scientific Instruments **68**, 939 (1997).